

Entrepôt de Données Global – Équité Salariale, Inégalités et Pouvoir du Travail

Auteurs: Mohamed Reguigui & Firas Taktak

Date: 2025

1



Made with GAMMA

Contexte & Problématique

La compréhension des inégalités mondiales est entravée par la dispersion des données entre des sources hétérogènes telles que WIID, ILOSTAT, la Banque Mondiale, l'UNDP et OWID. Chaque source présente des structures, formats, unités, années et définitions uniques, rendant l'analyse comparative complexe.

1

Sources Hétérogènes

WIID, ILOSTAT, Banque Mondiale, UNDP, OWID avec des structures et formats variés.

2

Fragmentation des Données

Absence de cohérence et d'harmonisation des indicateurs.

3

Besoin d'Intégration

Nécessité d'un entrepôt intégrateur, cohérent et structuré pour l'analyse.



Objectifs du Projet

01

Modélisation Dimensionnelle

Construire un modèle dimensionnel unifié pour l'économie, les inégalités et le développement humain, permettant une analyse intégrée et multidimensionnelle des données.

02

Harmonisation des Données

Harmoniser des données hétérogènes provenant de diverses sources, en gérant les différences de pays, d'années et d'unités de mesure pour assurer la comparabilité.

03

Automatisation ETL

Automatiser l'intégralité du pipeline ETL (Extraction, Transformation, Chargement) via des technologies robustes comme Python, Docker et Airflow, garantissant l'efficacité et la reproductibilité.

04

Chargement et Analyse

Charger les faits traités dans un environnement SQL Server, permettant ainsi une analyse multi-angle facilitée et la création de tableaux de bord interactifs pour les utilisateurs finaux.

Sources de Données

Pour construire cet entrepôt de données, nous avons intégré des informations provenant de sources internationales majeures, chacune apportant une perspective unique sur les inégalités et le développement.



WIID

Inégalités de revenus et distribution de la richesse.



ILOSTAT

Données sur l'emploi, le chômage, l'informalité et les salaires.



Banque Mondiale / UNDP

Indicateurs de développement humain et économique.



OWID

Statistiques sur la santé, la démographie et les dépenses publiques.

Profilage & Analyse Préliminaire

La phase initiale d'analyse a permis d'explorer les caractéristiques de chaque source de données, cruciale pour la détection et la correction des anomalies.

Processus de Profilage

- Exécution de scripts Python exploratoires.
- Vérification de la complétude et des duplications.
- Analyse des distributions pour chaque variable.
- Détection des incohérences structurelles, y compris les années manquantes et les codes pays divergents.


Cette étape est fondamentale pour garantir la qualité et l'intégrité des données avant toute transformation.

```
def exclude_israel(df: pd.DataFrame, iso_col: str = "iso3") -> pd.DataFrame:
    """Exclude rows where iso_col is in the configured EXCLUDE_ISO3 set."""
    s = df.get(iso_col, pd.Series(index=df.index, dtype=object))
    return df[~s.isin(EXCLUDE_ISO3)].copy()

def profile_block(df: pd.DataFrame, name: str) -> str:
    """Small textual profile block for a dataframe."""
    lines = [f"### {name}", f"- rows: {len(df):,}"]
    if "year" in df.columns:
        yrs = df["year"].dropna()
        if not yrs.empty:
            lines.append(
                f"- years: {int(yrs.min())}-{int(yrs.max())} "
                f"(distinct={yrs.nunique():,})"
            )
    if "iso3" in df.columns:
        lines.append(f"- countries: {df['iso3'].dropna().nunique():,}")
    top_nulls = df.isna().mean().sort_values(ascending=False).head(6)
    lines.append(
        "- top null ratios: "
        + ", ".join([f"{k}={v:.1%}" for k, v in top_nulls.items()])
    )
    return "\n".join(lines)
```

Modélisation Conceptuelle : Schéma Dimensionnel

Notre modèle dimensionnel est l'épine dorsale de l'entrepôt de données, structurant l'intégration et l'analyse. Chaque étape, de l'ETL à l'orchestration Airflow, adhère rigoureusement aux contraintes de grain, de clés et de hiérarchies définies dans ce schéma.



Dimensions

Les dimensions définissent le vocabulaire et le contexte de notre entrepôt, permettant une interprétation riche et nuancée des faits.

Dimensions Partagées

- Dim_Geography
- Dim_Time
- Dim_Indicator
- Dim_Economic_Classification
- Dim_Source

Dimensions Spécifiques

- Dim_Gender
- Dim_Age

Ces dimensions construisent le vocabulaire du warehouse. Sans elles, aucune interprétation n'est possible.

Tables de Faits

Les tables de faits contiennent les mesures quantitatives du processus métier, organisées autour d'un grain spécifique.

Fact_Economy

Fait Economie
geo_key
time_key
source_key
econ_class_key
genre_key
indicator_key
Value

Fact_Inequality

Fait Inégalité
geo_key
time_key
source_key
genre_key
indicator_key
economic_classification
Value

Fact_SocialDevelopment

Fait Developpement Social
geo_key
time_key
source_key
economic_classification
indicator_key
Value

Le grain, c'est-à-dire le niveau de détail le plus bas de la donnée, est crucial pour la cohérence et l'exactitude de l'analyse dans chaque table de faits.

Architecture Technique

Nous avons conçu l'infrastructure technique comme un composant logique essentiel de l'entrepôt de données, garantissant sa robustesse et sa maintenabilité.

1

Accès Sécurisé

SQL Server est accessible via un réseau privé sécurisé Tailscale.

2


ETL Encapsulé

Airflow et Docker encapsulent les processus ETL pour une gestion isolée.


3

Orchestration Reproductible

L'orchestration est entièrement reproductible, assurant la fiabilité des mises à jour.



ETL : Pré-traitements & Conception



1. Table de Correspondance

Établir une table de correspondance détaillée pour mapper les champs des sources de données brutes aux dimensions cibles de l'entrepôt de données, assurant une cohérence terminologique et structurelle.

2. Détection des Champs à Transformer

Identifier précisément les champs qui nécessitent des opérations de transformation spécifiques (nettoyage, agrégation, formatage) avant leur intégration dans l'entrepôt.


3. Identification des Opérations

Déterminer les types d'opérations nécessaires pour chaque champ identifié. Cela inclut :

- Mapping : Renommage ou reformatage simple.
- Jointure : Combinaison de données provenant de différentes sources.
- Décomposition : Division d'un champ en plusieurs nouveaux champs.
- Explosion : Génération de plusieurs enregistrements à partir d'un seul.
- Discrimination : Application de règles pour catégoriser ou filtrer des données.

4. Décision du Grain et des Clés

Définir le niveau de granularité souhaité pour chaque table de faits et établir les clés primaires et étrangères pour garantir l'intégrité référentielle et optimiser les performances des requêtes.



ETL : Implémentation Réelle

Nettoyage, Construction et Chargement

Nettoyage des CSV

Validation et standardisation des fichiers sources : suppression des doublons, gestion des valeurs manquantes, normalisation des formats de date et de nombres.

Construction des Tables de Faits

Agrégation et jointure des données transformées pour créer les tables de faits (Fact_Economy, Fact_Inequality, Fact_SocialDevelopment) selon le grain défini.

1

2

3

4

Construction des Dimensions (Scripts Python)

Exécution des scripts Python pour générer les tables de dimensions (Dim_Geography, Dim_Time, Dim_Indicator, etc.) avec gestion des hiérarchies et des clés de substitution.

Export en CSV Prêts à Charger

Génération de fichiers CSV intermédiaires validés et formatés, prêts pour l'insertion dans SQL Server.

Tailscale : Infrastructure Réseau pour un ETL Distribué et Sécurisé

Pourquoi Tailscale ?


Tailscale unifie des machines dispersées (Airflow, laptops, SQL Server) en un réseau privé unique, simplifiant l'accès sécurisé et la collaboration.

Rôles principaux dans notre projet :


- Connexion P2P sécurisée : Airflow (Docker), SQL Server (distant), machines de développement.
- Accès direct et sécurisé au SGBD Microsoft (sans exposition de ports/IP).
- Réseau unifié (LAN virtuel) pour tous les hôtes.
- Simplification du développement en binôme (URL/serveur, identifiants, expérience réseau uniformes).

Impact sur l'architecture ETL :

- Connexion Airflow-Data Warehouse via IP Tailscale stable.
- Chargements vers SQL Server fiables et sécurisés.
- Élimination des problèmes de compatibilité ("it works on my machine").



Airflow DAG – Orchestration Robuste du Pipeline



Notre pipeline n'est pas un script unique — c'est un DAG robuste, surveillable, exécutable quotidiennement.

Orchestration Centralisée

Airflow gère l'ensemble du workflow ETL avec dépendances explicites entre les tâches.

Surveillance en Temps Réel

Interface web Airflow pour monitorer l'exécution, les logs et les alertes.

Exécution Programmée

DAG configuré pour s'exécuter quotidiennement, garantissant la fraîcheur des données.

Gestion des Erreurs


Retry automatique, alertes en cas d'échec, traçabilité complète.

Reproductibilité

Chaque exécution est tracée et reproductible, essentiel pour l'audit et la maintenance.

Scalabilité

Architecture distribuée permettant le traitement parallèle des tâches indépendantes.



Résultat Final dans SQL Server

Dimensions construites et peuplées

Toutes les dimensions (Dim_Geography, Dim_Time, Dim_Indicator, Dim_Economic_Classification, Dim_Source, Dim_Gender, Dim_Age) sont complètement construites, validées et peuplées avec des données cohérentes et sans anomalies.

Faits cohérents, sans clés nulles

Les trois tables de faits (Fact_Economy, Fact_Inequality, Fact_SocialDevelopment) contiennent des mesures quantitatives agrégées au grain défini, avec intégrité référentielle garantie et aucune clé étrangère nulle.




Figure 5 – Tables dans SQL Server

Analyse Multidimensionnelle avec SQL Server Analysis Services

Une fois les dimensions et les faits chargés dans SQL Server, nous avons construit un cube OLAP SSAS pour transformer nos données en une ressource analytique puissante et interactive.

Exploration Rapide

Permet une navigation intuitive et une récupération rapide des données complexes.

Navigation Hiérarchique

Facilite l'analyse des données à différents niveaux de granularité (drill-down, roll-up).


Agrégations Dynamiques

Calcule des résumés en temps réel pour des performances optimales sur de grands volumes de données.

Analyse Multi-Axes

Offre la possibilité d'analyser les données selon diverses perspectives (temps, pays, indicateur, groupe d'âge, etc.).

Le cube matérialise la logique de schéma en étoile ou en flocon en une structure analytique facilement exploitable, prête pour la business intelligence et les tableaux de bord.



Structure du Cube SSAS

Notre cube OLAP SSAS transforme les données nettoyées et intégrées en une structure multidimensionnelle optimisée pour l'analyse, permettant une exploration rapide et des perspectives approfondies.




Figure 6 – Schéma du Cube SSAS

Mesures Intégrées

- **Value:** Mesure polymorphe pour les indicateurs variés.
- **Count:** Mesure calculée pour le profilage des données.
- **Agrégations:** SUM, AVG, MIN, MAX adaptées à chaque indicateur.

Dimensions du Cube

- Dim_Geography
- Dim_Time
- Dim_Indicator
- Dim_Gender
- Dim_Age
- Dim_Economic_Classification
- Dim_Source

"Le cube consolide toute la complexité des sources dans un espace multidimensionnel. Le monde devient pivotable."

Hiérarchies et Navigation Multidimensionnelle

“Les hiérarchies transforment le cube en véritable instrument d’analyse : zoom in, zoom out, comparer, segmenter.”



Dimension Géographie

continent → region_un →
subregion_un → country



Dimension Temps

year → (dynamic aggregations:
decade, quinquennial)



Dimension Indicateurs

domain → theme → category →
indicator_name




Figure 7 – Hiérarchies définies dans SSAS

Démonstration du Cube (Browser SSAS)

Voyons comment l'interface du Cube Browser permet une exploration intuitive de nos données multidimensionnelles.

01

Sélection du Continent

Filtrage des données pour **"Africa"**.

02

Comparaison des Indicateurs

Salaire min, Gini et taux d'activité .

03

Navigation Temporelle

Analyse des trajectoires par année.




Figure 8 – Exploration du Cube SSAS dans Excel

"En quelques clics, nous pouvons analyser les trajectoires nationales, comparer des régions, et détecter des ruptures économiques."

Intégration du Cube SSAS dans Power BI

L'intégration de notre cube SSAS avec Power BI débloque une exploration visuelle dynamique et intuitive, transformant les données complexes en insights actionnables pour tous les utilisateurs.

Connexion en Direct (Live Connection)

Power BI se connecte directement au cube SSAS, interrogeant les données en temps réel sans importation, garantissant que les rapports sont toujours à jour.

Performance Optimale

Tire parti du moteur de calcul haute performance de SSAS, permettant des analyses rapides même sur des volumes de données massifs.

Gouvernance Centralisée

Les règles de sécurité, les définitions de mesures et les hiérarchies sont gérées au niveau du cube, assurant une source unique de vérité et une cohérence des données.

Agrégations Pré-calculées

Les agrégations définies dans SSAS sont automatiquement exploitées par Power BI, accélérant les requêtes et simplifiant la création de rapports.




Figure 9 – Configuration de la connexion Power BI au cube SSAS

Indicateurs Clés de Performance (KPIs) pour l'analyse mondiale

Le Data Warehouse et le cube SSAS sont les fondations pour l'élaboration de KPIs pertinents et fiables.

Robustesse Analytique

Permettent de transformer les données brutes en mesures significatives, garantissant une analyse fiable.


Suivi des Dynamiques

Chaque KPI capture une évolution sociale ou économique, essentielle pour comprendre les tendances et les changements.

Interprétation Directe


Offrent une lecture simplifiée et directe des complexités du modèle multidimensionnel pour des insights clairs.

Ces indicateurs donnent une interprétation directe et actionnable de notre modèle multidimensionnel.




Visualisation des KPIs dans Power BI


Pour rendre nos Indicateurs Clés de Performance (KPIs) accessibles et actionnables, nous les avons intégrés dans des tableaux de bord Power BI interactifs. Cette approche offre une exploration visuelle approfondie des inégalités et de l'équité salariale à l'échelle mondiale, permettant des insights rapides et précis.



Gini Pondéré par Groupe de Revenus




Mesures d'Inégalité en Tunisie



Carte de l'Indice de Gini Mondial

Ces visualisations dynamiques transforment les données complexes en récits clairs, facilitant la prise de décision éclairée pour l'analyse des inégalités et des disparités salariales.

Architecture End-to-End (DW → SSAS → Power BI)



C'est une chaîne analytique complète : extraction, nettoyage, modélisation, calculs multidimensionnels et visualisation.

Performances & Optimisation SSAS

Pour maximiser la réactivité et l'efficacité de notre cube SSAS, nous avons intégré des techniques d'optimisation avancées. Ces pratiques garantissent des performances élevées et une expérience utilisateur fluide, même avec des volumes de données importants.



Agrégations Automatiques

Améliore la vitesse d'interrogation en pré-calculant les résumés de données les plus fréquemment sollicités.



Partitions Annuelles

Permet une gestion optimisée des données et accélère le traitement des requêtes sur des périodes spécifiques.



Relations d'Attributs

Définit les dépendances entre les attributs de dimension, améliorant les performances et la précision des requêtes.



Clés Substituts Précalculées

Facilite les jointures rapides entre les tables de faits et de dimensions, assurant l'intégrité et la rapidité des requêtes.



Mesures MDX Simplifiées

Rend les définitions de mesures plus efficaces et faciles à maintenir, réduisant la complexité des calculs multidimensionnels.

Ces optimisations sont cruciales pour un environnement analytique capable de gérer la complexité et le volume des données de notre entrepôt.

Conclusion

« Nous avons transformé un chaos de données mondiales en un entrepôt structuré, un cube multidimensionnel et un tableau de bord vivant — un instrument pour lire l'économie mondiale avec précision. »

MERCI POUR L'ATTENTION