
GLOBAL WAGE EQUITY, INEQUALITY & LABOR POWER DATA WAREHOUSE

*Rapport d'Ingénierie des Données et d'Architecture
Décisionnelle*

Mohamed Reguigui & Firas Taktak

Projet de fin de module Data Warehousing

Sous la direction de **Mme Senda Bouaziz**

7 décembre 2025

Résumé

Ce rapport détaille la conception, l'implémentation et le déploiement d'un système décisionnel distribué dédié à l'analyse macroéconomique des inégalités mondiales. Face à l'hétérogénéité des données socio-économiques (WIID, OIT, Banque Mondiale), nous avons développé une architecture ETL découplée (*Decoupled Staging Architecture*) orchestrée par Apache Airflow et conteneurisée sous Docker. Le système intègre un moteur de normalisation sémantique en Python, un stockage relationnel en constellation sous SQL Server, et une couche analytique multidimensionnelle (Cube SSAS) consommée par Power BI. Ce document explicite les choix d'ingénierie, de la résolution d'entités géographiques à la gestion des mesures semi-additives, en passant par la sécurisation des flux via un réseau maillé Tailscale.

Table des matières

1	Contexte et Périmètre Sémantique	3
1.1	Sources de Données Hétérogènes	3
1.2	Dictionnaire des Indicateurs Clés	3
2	Architecture Système et Infrastructure	4
2.1	Topologie Réseau et Sécurité (Tailscale)	4
2.2	Orchestration des Flux (Apache Airflow)	4
3	Ingénierie des Données : Stratégie de Transformation	5
3.1	Table de Correspondance (Source-to-Target Mapping)	5
3.2	Algorithme de Normalisation des Âges	6
4	Modélisation de l'Entrepôt (SQL Server)	7
4.1	Structure du Schéma	7
5	Couche Sémantique et Logique Métier (SSAS)	8
5.1	Gestion des Mesures Semi-Additives	8
5.2	Calculs MDX et Hiérarchies	9
6	Visualisation et Analyse (Power BI)	10
7	Conclusion	10

1 CONTEXTE ET PÉRIMÈTRE SÉMANTIQUE

L'objectif de ce projet est de construire un référentiel unique (*Single Source of Truth*) permettant de corréler la puissance syndicale, la structure du marché du travail et les inégalités de revenus à l'échelle mondiale.

1.1 Sources de Données Hétérogènes

L'entrepôt fédère des données issues de quatre fournisseurs institutionnels majeurs, chacun présentant des formats et des granularités divergents :

- **WIID (World Income Inequality Database) - UNU-WIDER** : Source principale pour les coefficients de Gini et les parts de revenus (Top 10%, Top 1%). Données caractérisées par une couverture temporelle irrégulière et des révisions fréquentes.
- **ILOSTAT (Organisation Internationale du Travail)** : Fournit les indicateurs structurels du marché du travail (Taux de syndicalisation, Chômage, Emploi informel). Défi majeur : Taxonomie des âges non standardisée.
- **Banque Mondiale (WDI)** : Indicateurs macroéconomiques (PIB par habitant, Inflation) et sociaux (Alphabétisation).
- **UNDP (Nations Unies) & OWID** : Indicateurs de développement humain (IDH) et données historiques sur les dépenses publiques.

1.2 Dictionnaire des Indicateurs Clés

Afin de structurer l'analyse, nous avons modélisé une dimension `Dim_Indicateur` hiérarchique regroupant les métriques suivantes :

Indicateurs du Marché du Travail (`Fact_Economy`)

- **Unemployment Rate** : Part de la population active sans emploi.
- **Youth NEET Rate** : Part des jeunes (15-24) ni en emploi, ni en études, ni en formation.
- **Informal Employment Rate** : Proportion de l'emploi exerçant dans le secteur informel (sans protection sociale).
- **Average Monthly Earnings** : Salaires moyens nominaux convertis en USD PPA.

Indicateurs d'Inégalité (`Fact_Inequality`)

- **Gini Coefficient** : Mesure synthétique de la dispersion des revenus (0 = égalité parfaite, 100 = inégalité totale).
- **Palma Ratio** : Ratio entre la part de revenu des 10% les plus riches et des 40% les plus pauvres.
- **Top 10% Income Share** : Concentration des richesses dans le décile supérieur.

2 ARCHITECTURE SYSTÈME ET INFRASTRUCTURE

Pour répondre aux contraintes de reproductibilité et de collaboration à distance, nous avons déployé une architecture "Container-First" distribuée.

2.1 Topologie Réseau et Sécurité (Tailscale)

Le défi principal consistait à permettre l'accès sécurisé à une instance **Microsoft SQL Server** unique depuis plusieurs environnements (Postes développeurs, Conteneur Airflow, Service Cube) sans exposer le port 1433 sur l'internet public.

Nous avons implémenté un réseau privé virtuel maillé (*Mesh VPN*) via **Tailscale**.

- **Principe** : Chaque nœud du système (Docker, PC) reçoit une IP privée stable (ex : 100.77.63.59) dans le réseau virtuel *Tailnet*.
- **Implémentation** : Le service Airflow, défini dans `docker-compose.yml`, communique avec la base de données via cette IP sécurisée, garantissant une isolation totale du trafic de données.




FIGURE 1 – Topologie de l'infrastructure distribuée sécurisée par Tailscale.

2.2 Orchestration des Flux (Apache Airflow)

Le pipeline de données est orchestré par un **Graphe Acyclique Dirigé (DAG)** sous Apache Airflow (`gweilpdw_etl_dag.py`). Cette approche garantit l'idempotence des traitements et la gestion fine des dépendances.

Le workflow se décompose en 4 tâches séquentielles :

1. **Extraction & Transformation (run_dw_etl)** : Exécution du code Python pur (`run_all.py`) pour extraire, nettoyer et normaliser les données en fichiers plats (CSV).

2. **Profilage Qualité (run_data_profiling)** : Audit automatique des fichiers générés (taux de NULLs, cardinalité) avant chargement.
3. **Chargement (write_data_to_mssql)** : Insertion en masse via pyodbc avec gestion transactionnelle.
4. **Validation** : Vérification de la cohérence finale.




FIGURE 2 – Visualisation du DAG Airflow illustrant le pipeline séquentiel.

3 INGÉNIERIE DES DONNÉES : STRATÉGIE DE TRANSFORMATION

Notre approche ETL se distingue par une phase intensive de **pré-traitement sémantique** en Python avant tout chargement en base. Cette "Zone de Quarantaine" permet d'appliquer des heuristiques complexes impossibles à réaliser en SQL pur.

3.1 Table de Correspondance (Source-to-Target Mapping)

Le tableau suivant documente la logique de transformation appliquée pour harmoniser les sources disparates vers le modèle canonique.

CodeBack Source	Champ Source	Algorithme de Transformation (Python)	Champ Cible
ILOSTAT	classif1.label	Regex Bucketing : Extraction des patterns "15-24", "25-54", "55+" et rejet des agrégats chevauchants ("15+", "Youth").	Dim_Age. age_group

CodeBack Source	Champ Source	Algorithme de Transfor- mation (Python)	Champ Cible
ILOSTAT	sex.label	Standardisation Catégorielle : Mapping explicite ("Male"→"M", "Female"→"F") via dictionnaire.	.gender_code
World Bank	NY.GDP.MKTP.CD	Type Casting Strict : Parsing des chaînes, suppression des séparateurs ",", conversion en FLOAT64.	Economy.value
WIID	gini_reported	Interpolation Temporelle : Comblement des trous (gaps < 2 ans) par interpolation linéaire pour lisser les séries.	Inequality.value
Toutes	country_name	Fuzzy Entity Resolution : Distance de Levenshtein (seuil 0.88) pour aligner les toponymes vers ISO-3166 alpha-3.	Geographyiso3

TABLE 1 – Matrice de Correspondance Sémantique

3.2 Algorithme de Normalisation des Âges

La gestion des tranches d'âge de l'OIT nécessitait une logique ad-hoc pour éviter les doublons lors des agrégations. Le script `transformations.py` implémente un filtre par expression régulière :




FIGURE 3 – Logique de segmentation et de normalisation des cohortes d'âge.

```

1 def map_age_group(age_series):
2     # Logique : Priorit aux bandes d'annales pour viter les double
   -comptes
3     mask = age_series.str.contains(r"Age \((10-year bands\):"), na=False)
4
5     # Projection vectoris e vers les dimensions canoniques
6     conditions = [
7         mask & age_series.str.contains(r"15-24"),           # -> Youth
8         mask & age_series.str.contains(r"25-34|35-44|45-54"), # -> Prime
   Age
9         mask & age_series.str.contains(r"55-64|65\+")       # -> Senior
10    ]
11    # ...

```

4 MODÉLISATION DE L'ENTREPÔT (SQL SERVER)

Le schéma physique, défini dans `Schema Creation.sql`, suit une architecture en **Constellation** (Galaxy Schema) composée de trois tables de faits partageant des dimensions conformes.

4.1 Structure du Schéma

- **Fact_Economy** : Grain fin [Pays, Année, Sexe, Âge]. Mesures : Emploi, Salaires.
- **Fact_Inequality** : Grain agrégé [Pays, Année, Source]. Mesures : Gini, Palma.
- **Fact_SocialDevelopment** : Grain agrégé. Mesures : IDH, Dépenses Santé.

Les dimensions `Dim_Geography` et `Dim_Time` agissent comme les pivots centraux permettant l'analyse croisée (*Drill-Across*).




FIGURE 4 – *Modèle Entité-Association : Schéma en Constellation avec Dimensions Partagées.*

5 COUCHE SÉMANTIQUE ET LOGIQUE MÉTIER (SSAS)

Pour dépasser les limitations du SQL brut, nous avons implémenté un Cube OLAP (Projet Visual Studio **CubeDeDonnées**) déployé sur SQL Server Analysis Services (SSAS).

5.1 Gestion des Mesures Semi-Additives

L'un des défis majeurs traités concerne l'agrégation temporelle des indicateurs de stock (Gini, Taux de Chômage).

- **Problème** : Une somme standard (SUM) sur l'axe temporel est sémantiquement fausse (Somme des taux de chômage sur 10 ans).
- **Solution Technique** : Configuration de la propriété **AggregateFunction** sur **LastNonEmpty**.
- **Comportement** : Lors d'une analyse sur une décennie, le Cube renvoie automatiquement la valeur de la dernière année disponible, garantissant la cohérence métier.




FIGURE 5 – Configuration des mesures semi-additives dans Visual Studio (SSAS).

5.2 Calculs MDX et Hiérarchies

Le Cube intègre des membres calculés (Calculated Members) pour enrichir l'analyse :

- **Hiérarchie Géographique** : Continent → Région → Pays (permettant le *Roll-Up* automatique).
- **Moyennes Pondérées** : Les agrégats régionaux sont pondérés par la population (Dim_Geography.Population) pour éviter le biais des petits états.

Dimension	Hierarchy	Operator	Filter Expression	Parameters
Dim Geography	Continent	Equal	{ Africa }	☐
Dim Indicator	Indicator Name	Equal	{ Gini Index (WID), Labour Force Participation Rate, Minimum Wage }	☐
<Select dimension>				☐

Year	Value - Fact Social Development	Value - Fact Inequality	Value
1993	(null)	486.97929008545	4782.2
1994	(null)	386.601169586182	6916.651
1995	1375.261	625.175197601318	2072.57
1996	1330.956	314.158729553223	4986.17
1997	1312.9	331.701072692871	5577.06
1998	1632.585	313.436431884766	6556.46
1999	1997.183	206.501327514648	7957.147
2000	3448.964	240.352333068848	6336.024
2001	3400.49	502.108016967773	10277.557
2002	3641.065	373.922958374023	7961.906
2003	3898.957	581.629070281982	8097.338
2004	5199.327	286.261085510254	10588.476
2005	5948.977	530.876712799072	14901.535
2006	6115.862	494.374073028564	12099.609
2007	6144.086	478.880798339844	5773.08
2008	5887.571	304.465858459473	9199.968
2009	6300.396	370.265354156494	9521.845
2010	6968.657	613.451320648193	19621.171
2011	7480.52	605.875522613525	21443.954
2012	8147.415	456.453973770142	16135.591
2013	8602.323	316.538879394531	19994.9
2014	8727.106	570.750915527344	26738.507
2015	8770.656	446.013740539551	15331.637
2016	8886.746	456.888671875	13597.245
2017	8894.431	703.627918243408	20883.732
2018	9033.274	234.760608673096	14623.207
2019	9304.885	642.046073913574	31013.582
2020	9339.841	369.038318634033	14481.87
2021	9383.647	254.705062866211	20451.49

FIGURE 6 – Exploration interactive des données agrégées via le navigateur de Cube SSAS.

6 VISUALISATION ET ANALYSE (POWER BI)

L'interface finale consomme le Cube en mode *Live Connection*, déléguant tous les calculs au moteur OLAP.

Les tableaux de bord réalisés permettent d'analyser :

1. La corrélation inverse entre **Densité Syndicale** et **Part du Top 10%** (Hypothèse de compression salariale).
2. L'évolution temporelle de l'Indice de Gini par continent.
3. Les disparités de genre sur le marché du travail (Écart salarial, NEET).




FIGURE 7 – *Exemple d'Un Tableau de bord : Analyse des Inégalités et du Marché du Travail.*

7 CONCLUSION

Ce projet valide la pertinence d’une architecture hybride pour l’analyse des données macroéconomiques. La combinaison d’un ETL Python flexible (pour la normalisation complexe) et d’un Cube SSAS rigoureux (pour l’agrégation métier) offre une plateforme robuste, capable de révéler les dynamiques structurelles des inégalités mondiales avec une précision et une traçabilité totales.